



Universidad Nacional de Rosario
Licenciatura en Ciencias de la Computación

Predicción de penales mediante Transfer Learning sobre InceptionV3

Introducción a la Inteligencia Artificial

Integrantes

López Agustín

Lynn Bosio Baltazar

1. Introducción y objetivo

El arquero debe decidir un lado en el momento del disparo. Si una red puede anticipar la dirección del tiro mirando la postura del pateador desde atrás, el sistema tendría valor práctico como apoyo o como estudio de qué información visual está disponible en esa vista.

Nuestro objetivo fue, a partir de imágenes del cuerpo completo del jugador al momento del impacto con la pelota (y frames cercanos previos), estimar la dirección del remate y comparar esa estimación con lo que efectivamente eligió el arquero en el mismo tiro.

2. Construcción del dataset

2.1. Fuente y limitación de tamaño

Recolectamos imágenes de penales en transmisiones oficiales de partidos profesionales (tanto en tandas de penales como penales pateados durante el partido) grabados con cámara ubicada *detrás* del jugador que ejecuta. Esa toma muestra el cuerpo del pateador de la forma más clara posible, al poder distinguir la postura, la inclinación del cuerpo y la posición de las piernas, pero es una cámara relativamente nueva en las transmisiones y no estandarizada, es decir, no hay tantos partidos grabados desde esta posición e incluso en los partidos en que sí se utiliza, se puede llegar a intercambiar con otras posiciones de cámara que no eran útiles para el estudio.

Dadas estas limitaciones fue posible armar un dataset original de 449 penales distintos. Estas imágenes solo muestran al pateador en el momento del impacto, por lo que analizamos si agregando momentos anteriores al golpe seguía siendo útil la información. Notamos que desde que el pie no hábil del jugador se apoya al lado de la pelota, había alrededor de 2 frames extra que podrían ayudarnos. Por lo que finalmente terminamos con 1414 imágenes en el dataset provenientes de 449 penales diferentes.

Cada disparo se identificó de forma única (`penal_id`) para evitar que imágenes similares de un mismo penal queden distribuidas entre train y test dándonos una falsa sensación de aprendizaje cuando, en vez de aprender por la postura del cuerpo del jugador, asimila todo el resto de información de la imagen (pelo del jugador, uniforme, número, etc.).



Figura 1: Penal de referencia

2.2. Etiquetado de cada imagen

2.2.1. Etiqueta de gol

Para cada penal etiquetamos el punto donde la pelota cruza la línea de meta, visto desde la cámara, con un par continuo (x, y) donde

$$x \in \mathbb{R}, \quad y \in \mathbb{R}_0^+$$

El $(0, 0)$ está ubicado en la intersección de la línea de meta en el suelo con el palo izquierdo del arco visto desde la cámara del pateador, mientras que el $(1, 1)$ se encuentra en el cruce entre el travesaño y el palo derecho visto desde el pateador.

A partir de la coordenada horizontal x definimos las etiquetas discretas para clasificación. En tres clases (izquierda / centro / derecha):

$$\text{lado}(x) = \begin{cases} 0 & \text{si } x < 0,4 \quad (\text{izquierda}), \\ 1 & \text{si } 0,4 \leq x \leq 0,6 \quad (\text{centro}), \\ 2 & \text{si } x > 0,6 \quad (\text{derecha}). \end{cases}$$

En la versión binaria (izquierda / derecha):

$$\text{bin}(x) = \begin{cases} 0 & \text{si } x < 0,5 \quad (\text{izquierda}), \\ 1 & \text{si } x \geq 0,5 \quad (\text{derecha}). \end{cases}$$

2.2.2. Etiqueta de arquero

Por otro lado, si bien al pensar en una clasificación el baseline de resultados es el porcentaje de la clase mayoritaria (en este caso, equivalente a tirarse siempre al mismo lado), al ser un deporte entre 2 equipos, donde cada jugador puede analizar lo que está pasando, sería contraproducente que el arquero elija siempre el mismo lado, ya que para el pateador sería tan fácil como elegir el lado opuesto para patear. Por lo tanto, decidimos etiquetar en cada penal la dirección en la que el arquero se tiró para tener una medición más cercana a la realidad de qué porcentaje de penales fueron adivinados (más allá de si se pudieron atajar o no) para comparar el rendimiento de nuestro modelo con los verdaderos arqueros encargados de atajar los penales.

Para esto se usaron las siguientes etiquetas:

- **L:** Izquierda del pateador.
- **R:** Derecha del pateador.
- **CL y CR:** Si se quedó en el centro pero amagó hacia algún lado y lo corrigió (de utilidad más adelante para pasar de clasificación ternaria a binaria).

Esto nos deja finalmente con un CSV en donde cada imagen está etiquetada de la siguiente forma:

`penal_<competición>_<año>_<equipo1>_<equipo2>_<nro_penal>_<nro_frame>,<x>,<y>,<L/R/CL/CR>`

Donde cada frame proveniente de un mismo penal hereda las coordenadas y lado del arquero de la imagen original.

3. Metodología

3.1. Arquitectura y transfer learning

Para mitigar el riesgo de sobreajuste debido al tamaño reducido del dataset, aplicamos **Transfer Learning** utilizando la red convolucional **InceptionV3** preentrenada en *ImageNet*.

Sobre la salida de InceptionV3 (con *Global Average Pooling*), acoplamos una cabeza clasificadora/regresora liviana configurada de la siguiente manera:

- **Capa de Dropout** ($p = 0,2$): Desconecta aleatoriamente el 20 % de los rasgos extraídos por el backbone durante el entrenamiento. Esta regularización evita que la cabeza densa memorice combinaciones específicas de rasgos en imágenes con alta correlación (por ejemplo, múltiples frames de un mismo partido).
- **Capa Densa intermedia (64 unidades + activación ReLU)**: Reduce la dimensionalidad de las características antes de la proyección final a las salidas del problema (coordenadas (x, y) para regresión, o distribución de probabilidades Softmax/Sigmoid para clasificación).

3.2. Estrategia de entrenamiento de dos fases y Fine-tuning

El proceso de entrenamiento se dividió en dos etapas bien diferenciadas para preservar los pesos preentrenados y evitar el desvanecimiento o explosión de gradientes:

1. **Fase de la Cabeza (Head Training)**: Se mantiene congelado todo el *backbone* de InceptionV3 y se entrena únicamente la cabeza densa recién añadida. Se utiliza el optimizador Adam con un *learning rate* inicial relativamente alto de $\eta = 10^{-3}$ durante 16 épocas. Esto permite que los pesos inicializados al azar en la cabeza converjan rápidamente a un estado estable sin alterar las representaciones profundas de InceptionV3.
2. **Fase de Fine-Tuning**: Se descongelan únicamente las últimas 40 capas del *backbone* de InceptionV3, manteniendo fijas las capas iniciales e intermedias. Descongelar únicamente un bloque final pequeño asegura adaptar los patrones de muy alto nivel a la geometría del cuerpo y el pie del pateador, minimizando el riesgo de destruir las características generales aprendidas en ImageNet. En esta fase se utiliza Adam con un *learning rate* marcadamente bajo ($\eta = 3 \cdot 10^{-5}$) y se entrena hasta un máximo de 40 épocas.

Para controlar el Fine-Tuning de forma dinámica:

- **ReduceLROnPlateau**: Reduce el *learning rate* a la mitad si *val_loss* no mejora durante 3 épocas consecutivas (*patience* = 3), permitiendo sintonizar la convergencia en zonas llanas de la función de pérdida.
- **Early Stopping**: Detiene el entrenamiento si *val_loss* no mejora tras 8 épocas consecutivas, restaurando automáticamente los mejores pesos registrados en el punto de menor error de validación.

3.3. Validación cruzada con StratifiedGroupKFold (5-fold)

Debido al tamaño limitado del conjunto de datos y a la estructura particular del problema (donde existen múltiples imágenes provenientes de un mismo evento o tiro de penal), un split aleatorio estándar *train/validation* generaría *data leakage* o sesgos severos.

Para solucionar esto, empleamos la técnica **StratifiedGroupKFold** con $k = 5$ sobre el conjunto de desarrollo (*dev*, 85 % de los penales totales, reservando el 15 % restante como un test *hold-out* completamente aislado):

- **Agrupamiento por penal_id (GroupKFold):** Garantiza que todos los frames y aumentaciones pertenecientes a un mismo tiro de penal se asignen estrictamente al mismo fold (ya sea entrenamiento o validación). Esto previene que la red sea evaluada en imágenes casi idénticas a las vistas en entrenamiento.
- **Estratificación por clase (Stratified):** Mantiene una distribución balanceada y representativa de las clases objetivo (dirección del tiro $L/C/R$) a lo largo de cada uno de los 5 folds.

En cada una de las 5 particiones se entrena un modelo independiente. Las predicciones sobre los conjuntos de validación *out-of-fold* u OOF permiten evaluar la capacidad de generalización real del modelo en *dev*, mientras que para la inferencia en el conjunto de test final se promedian las probabilidades y coordenadas predichas por el conjunto de las 5 redes.

3.4. Data augmentation

- **Flip horizontal:** Como es importante la orientación del cuerpo para nuestro análisis, la única modificación posicional posible que no perjudique al dataset es espejar la imagen horizontalmente. Es necesario ajustar las etiquetas de gol para preservar la relación postura-gol que analizamos, $x_1 = 1 - x_0$, e invertir las etiquetas izquierda↔derecha. Duplica efectivamente los ejemplos respetando la simetría del arco.
- **Brillo y contraste aleatorios:** Cambian la apariencia fotométrica sin alterar la geometría de la postura. Como no nos interesa el césped, la camiseta ni nada que dependa de los colores de la imagen, es de gran utilidad modificar estos aspectos para que el aprendizaje de nuestra red no haga foco en propiedades de la imagen que no son de importancia.

4. Evolución del planteo del problema

El desarrollo del trabajo práctico no fue un único experimento estático, sino un proceso de refinamiento del objetivo en función de la capacidad de aprendizaje demostrada por la arquitectura y el tamaño del dataset.

Inicialmente fue el enfoque más ambicioso, en donde intentamos predecir las coordenadas continuas (x, y) del impacto en el arco. Sin embargo, dada la alta varianza del problema sumada a las limitaciones del volumen de datos, simplificamos progresivamente la tarea a clasificación discreta ternaria ($L/C/R$) y, finalmente, a clasificación binaria (L/R).

Dentro de esta evolución fue cuando decidimos el aumento del dataset de 1 frame del impacto del penal a varios (desde que el pie no hábil se apoya y se conserva la postura general), además de la inclusión del lado al que adivina el arquero para ayudarnos en el análisis de valores reales de predicción de penales.

Sumado a los frames adicionales, incorporamos 2 formas distintas de predicción: por frame y por penal.

- **Por frame:** Cada frame es tratado como un penal independiente, lo cual nos da un dataset mayor, pero puede pasar que frames distintos de un mismo penal arrojen resultados distintos.
- **Por penal:** Se agrupan los frames pertenecientes a un mismo penal y se promedian los resultados, ya sea la posición exacta (x, y) o la probabilidad de cada lado.

5. Análisis de curvas de entrenamiento y validación OOF (Loss, Huber y MAE)

El monitoreo de las métricas *Out-Of-Fold* (OOF) a lo largo de las 5 particiones permitió diagnosticar la dinámica de convergencia y la prevención del sobreajuste en cada modelo:

- **Curvas en Regresión (Pérdida Huber y MAE):** Durante la primera fase (entrenamiento de la cabeza con Huber(0,25) y $\eta = 10^{-3}$), la pérdida de entrenamiento se redujo rápidamente a $\sim 0,064$ con un MAE $\approx 0,363$. Sin embargo, en la fase de *Fine-Tuning* ($\eta = 3 \cdot 10^{-5}$), mientras la pérdida en *train* descendió hasta $\sim 0,018$ (MAE $\approx 0,158$), la pérdida de validación OOF y el MAE en validación se estancaron en $\text{val_loss} \approx 0,051$ y $\text{val_MAE} \approx 0,292 \pm 0,008$. La discrepancia creciente confirmó la incapacidad del *backbone* para ajustar relaciones espaciales continuas sin caer en memorización.
- **Curvas en Clasificación (Entropía Cruzada):** En las tareas de clasificación (L/C/R y L/R), la pérdida categórica/binaria de entrenamiento mostró una caída fluida hasta valores cercanos a 0,05. No obstante, las curvas de *val_loss* alcanzaron su punto óptimo rápidamente (entre las épocas 1 y 4 del *Fine-Tuning*), activando los mecanismos de *Early Stopping*. Restaurar los pesos del punto de menor error de validación evitó que el sobreajuste degradara el desempeño general.

6. Resultados experimentales y análisis

La evaluación final se realizó sobre el conjunto de test *hold-out* (68 penales, 216 frames) mediante el *ensemble* por promediado de las 5 redes entrenadas en los folds de validación cruzada.

6.1. Experimento A: Regresión continua de coordenadas (x, y)

En la tarea de regresión previa se utilizó la función de pérdida Huber. Al evaluar sobre el conjunto de test se obtuvieron los siguientes resultados:

- **Error Absoluto Medio (MAE):** $\text{MAE}_x = 0,241$, $\text{MAE}_y = 0,162$, con un MAE promedio combinado de 0,289.
- **Dispersión de predicciones:** Mientras que la desviación estándar real de la coordenada x en el dataset es $\text{std}(x) = 0,312$, la desviación estándar de las coordenadas predichas fue de solo $\text{std}(\hat{x}) = 0,070$.

Análisis: Las gráficas de dispersión mostraron un claro fenómeno de *colapso al centro*. Al ser la posición del remate un problema de alta varianza con un dataset acotado, la red minimizó la pérdida cuadrática prediciendo sistemáticamente un punto medio cercano al centro geométrico del arco (0,50,0,40), perdiendo la capacidad de discriminar tiros esquinados. Por tanto, la regresión continua se descartó como herramienta de localización útil.

6.2. Experimento B: Clasificación Ternaria (L / C / R)

Luego de los resultados vistos en el experimento de regresión, optamos por un enfoque más conservador: limitarnos a 3 opciones posibles (pensando que somos el arquero y queremos optimizar las chances de atajar). Dividir el arco en 3 partes según su coordenada x en donde el arquero tendría 3 opciones (quedarse en el medio, tirarse a la izquierda o a la derecha), aunque sea una simplificación, sigue siendo muy cercano al accionar real de los arqueros, por lo que creemos que no pierde utilidad ni propósito el experimento.

Se entrenó con pérdida de entropía cruzada categórica. Al evaluar los 216 frames y los 68 penales del conjunto de test se obtuvieron los siguientes resultados:

- **Evaluación por Frame (216 frames):** Accuracy del modelo = **43,5 %** (94/216 aciertos).
- **Evaluación por Penal (68 penales):** Accuracy del modelo = **47,1 %** (32/68 aciertos).
- **Baseline del Arquero (humano):** 41,2 % (28/68 penales).

- **Baseline de Clase Mayoritaria:** 47,1 % (tiros a la izquierda).

Análisis: La agregación por penal logró un incremento de +3,6 % de precisión frente a la evaluación aislada frame por frame, confirmando que promediar los resultados suaviza discrepancias cuando cuadros del mismo tiro difieren. No obstante, el modelo sufrió una confusión severa en la clase ‘Centro’ debido a la escasez de datos ($\sim 12\%$ de los disparos). La prueba de McNemar entre la predicción por penal y el arquero arrojó un valor $p \approx 0,562$ ($p > 0,05$), confirmando que en 3 clases el modelo no logra una ventaja estadísticamente significativa respecto al arquero y no llega a superar al predictor trivial mayoritario, en el mejor caso lo iguala.

6.3. Experimento C: Clasificación Binaria (L / R) (Modelo Principal)

Por último, probamos una última simplificación en donde se dividió el arco en 2 y se reasignaron las direcciones del penal a partir de la línea del medio del arco. Los disparos al centro y las veces en las que el arquero decidió quedarse quieto fueron reevaluados una última vez para asignarlos al lateral más próximo dada una revisión final del material. Al constar de dos clases balanceadas con los suficientes casos de estudio, la clasificación binaria entre Izquierda y Derecha presentó el mejor comportamiento predictivo:

- **Evaluación por Frame (216 frames):** Accuracy del modelo = **64,4 %** (139/216 aciertos).
- **Evaluación por Penal (68 penales):** Accuracy del modelo = **66,2 %** (45/68 aciertos).
- **Baseline del Arquero humano:** 47,1 % (32/68 penales).
- **Baseline de Clase Mayoritaria:** 52,9 %.
- **Mejora relativa (Δ Modelo Penal vs Arquero):** +19,1 %.

Análisis: La comparación directa entre la evaluación por frame (64,4 %) y por penal (66,2 %) ratifica la ganancia del promedio de imágenes (+1,8 %). A nivel de disparo ($n = 68$), la matriz de aciertos cruzados se resume en:

	Arquero Correcto	Arquero Incorrecto
Modelo Correcto	21 (Ambos OK)	24 (Solo Modelo)
Modelo Incorrecto	11 (Solo Arquero)	12 (Ambos Fallan)

Aplicando el test de McNemar sobre los penales discordantes ($b = 24$, $c = 11$):

$$\chi^2 = \frac{(|24 - 11| - 1)^2}{24 + 11} = \frac{144}{35} \approx 4,114 \implies p = 0,0410$$

Dado que $p < 0,05$, el resultado es estadísticamente significativo. La red no solo supera a la clase mayoritaria y a la evaluación frame por frame, sino que demuestra una capacidad superior a la del arquero para anticipar la dirección del tiro.

Validación y consistencia de los resultados OOF frente al Test: Al analizar la evaluación *Out-Of-Fold* a nivel de penal en el conjunto de desarrollo *dev* ($n = 381$), se obtuvo un 43,6 % en L/C/R ($\Delta = +0,0\%$ respecto al arquero 43,6 %, $p = 1,0000$) y un 56,4 % en L/R ($\Delta = +6,3\%$ sobre el arquero 50,1 %, $p = 0,0879$). Aunque existen fluctuaciones en los porcentajes absolutos frente al conjunto de test (donde L/R alcanzó un 66,2 %), los resultados OOF se consideran plenamente válidos como señal de aprendizaje libre de sobreajuste. Esta variación responde de manera esperable a dos factores: por un lado, a nivel OOF se promedia el desempeño de 5 modelos independientes evaluados individualmente, mientras que en test se utiliza un *ensemble* por promediado de las 5 redes, reduciendo fuertemente la varianza de las

predicciones; por otro lado, el tamaño acotado del dataset introduce una variabilidad estadística natural. Lo decisivo es que la tendencia general se mantiene absolutamente coherente: la tarea en 3 clases no logra diferenciarse de la decisión humana, mientras que la tarea binaria L/R consolida una ventaja predictiva real sobre el arquero en ambas evaluaciones.

6.4. Resumen Comparativo de Métricas

En la Tabla 1 se consolidan los resultados en test comparando ambas perspectivas de agregación:

Cuadro 1: Comparativa de desempeño por Frame vs por Penal en el conjunto de test (68 penales / 216 frames).

Tarea / Experimento	Modelo (Frame)	Modelo (Penal)	Arquero	McNemar (p)
A) Regresión (x, y)	MAE = 0,295	MAE = 0,289	–	–
B) Clasificación L/C/R	43,5 % (94/216)	47,1 % (32/68)	41,2 % (28/68)	0,562 (No signif.)
C) Clasificación L/R	64,4 % (139/216)	66,2 % (45/68)	47,1 % (32/68)	0,0410 (Significativo)

El promediado de probabilidades por `penal_id` incrementó la precisión entre un +1,8 % y +3,6 % respecto a la evaluación aislada frame por frame, confirmando la efectividad del filtrado de ruido temporal.

7. Conclusión

El recorrido del trabajo fue de lo más ambicioso a lo más contrastable con la decisión humana.

La regresión continua (x, y) no fue un estudio con resultados esperanzadores, en donde con pocos datos la red colapsa al centro y no localiza bien el remate.

El enfoque L/C/R mostró una mejora con respecto a la regresión, pero empatada con la mayoritaria y sin evidencia clara de superar al arquero, donde podría llegar a mejorar solucionando la disparidad del dataset dada por la poca cantidad de penales pateados al centro que fueron recopilados.

Por último, el experimento mostró resultados favorecedores al simplificar a L/R, sumando frames previos (postura con pie de apoyo asentado).

Sirvió el diseño experimental adaptado al tamaño chico del dataset: InceptionV3 con fine-tuning de pocas capas, 5-fold agrupado, flips con corrección de etiqueta, augmentación fotométrica orientada a la postura, ensemble en test y promedio de penal.

En síntesis: con una cámara trasera y un dataset limitado, no logramos localizar con precisión el punto de llegada de la pelota, pero sí una estimación binaria del lado que mejora de forma significativa la decisión observada del arquero en el hold-out. Lo cual nos sugiere que hay información útil en la postura previa e inmediata al impacto, e incluso deja la puerta abierta a resultados mejores en casos de estudio donde el limitante no sea la cantidad de penales encontrados.